

Пособие по статистическим тестам для анализа данных

Это пособие систематизирует основные статистические методы, которые используются в анализе данных и A/B-экспериментах. В нём рассматриваются z-тесты, t-тесты, критерий χ^2 , интерпретация p-value, ошибки I и II рода, расчёт объёма выборки, а также бутстрап и перестановочные тесты.

Общие понятия

Статистические тесты позволяют принимать решения на основе выборочных данных. В основе большинства тестов лежит проверка нулевой гипотезы (H_0) против альтернативной гипотезы (H_1) . Выбирается статистика теста, рассчитывается её значение по данным, затем определяется вероятность получить столь же экстремальные значения при верной (H_0) — p-value. Если эта вероятность меньше заранее заданного уровня значимости (α) , (H_0) отвергают.

Z-тесты

Z-тесты используются для проверки гипотез о средних или долях, когда распределение тестовой статистики при (H_0) аппроксимируется нормальным распределением. Обычно требуется большая выборка и известное или хорошо оцениваемое стандартное отклонение. Z-тесты также широко применяются для проверки долей (конверсий).

Предпосылки z-теста

Независимость наблюдений. Большая выборка или нормальное распределение выборочных средних (центральная предельная теорема). Для теста среднего известно стандартное отклонение (σ) генеральной совокупности либо используется выборочная оценка при большом (n) . Для тестов пропорций требуется, чтобы ожидания по успехам и неудачам не были малы: $(n \cdot p \geq 10)$ и $(n \cdot (1-p) \geq 10)$.

Одновыборочный z-тест для среднего

Проверяется гипотеза $(H_0: \mu = \mu_0)$ при известном (σ) . Статистика:

$$z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}},$$

где $(\bar{x})$ — выборочное среднее, (n) — объём выборки. Z-статистика распределена стандартно нормально при (H_0) .

Одновыборочный z-тест для пропорции

Проверяется $(H_0: p = p_0)$. Статистика:

$$z = \frac{\hat{p} - p_0}{\sqrt{p_0 (1 - p_0) / n}},$$

где $(\hat{p})$ — выборочная доля успехов.

Двухвыборочный z-тест для средних

Для двух независимых выборок проверяют $(H_0: \mu_1 - \mu_2 = 0)$. Пусть (σ_1, σ_2) известны. Тогда:

$$z = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}},$$

где $(\bar{x}_i)$, (n_i) — среднее и объём каждой выборки.

Двухвыборочный z-тест для пропорций

Проверяется $(H_0: p_1 = p_2)$. Вычисляется объединённая оценка $(\hat{p} = \frac{x_1 + x_2}{n_1 + n_2})$. Статистика:

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p}) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

где $(\hat{p}_i = x_i/n_i)$.

Многовыборочные аналоги

Z-тест используется для одной или двух групп. Для более чем двух групп применяют ANOVA (F-тест) для средних или критерий χ^2 для категориальных данных. При множественных сравнениях корректируют уровень значимости (например, методом Холма).

Код: реализация z-тестов на Python

```
import numpy as np
from scipy import stats

# z-тест для средних (sigma известно)
def ztest_mean_1samp(x, mu0, sigma):
    n = len(x)
    xbar = np.mean(x)
    se = sigma / np.sqrt(n)
    z = (xbar - mu0) / se
    p = 2 * (1 - stats.norm.cdf(abs(z)))
    return z, p

# z-тест для пропорций
def ztest_prop_1samp(x, n, p0):
    phat = x / n
    se0 = np.sqrt(p0 * (1 - p0) / n)
    z = (phat - p0) / se0
    p = 2 * (1 - stats.norm.cdf(abs(z)))
    return z, p

# z-тест для пропорций (A/B)
def ztest_prop_2samp(x1, n1, x2, n2):
    p1 = x1 / n1
    p2 = x2 / n2
    p_pool = (x1 + x2) / (n1 + n2)
    se0 = np.sqrt(p_pool * (1 - p_pool) * (1/n1 + 1/n2))
    z = (p1 - p2) / se0
    p = 2 * (1 - stats.norm.cdf(abs(z)))
    return z, p
```

Функции возвращают z-статистику и двустороннее p-value.

Т-тесты

Т-тесты проверяют гипотезы о средних, когда стандартное отклонение генеральной совокупности неизвестно. Тестовая статистика имеет распределение Стьюдента. Т-тесты широко применяются при сравнении средних (например, ARPU, время).

Предпосылки t-теста

Независимость наблюдений. Нормальность распределения метрик или достаточно большая выборка (асимптотическая нормальность). Student-тест предполагает равенство дисперсий; Welch-тест — нет. Парный t-тест анализирует разности парных наблюдений, распределение которых должно быть симметричным.

Одновыборочный t-тест

Проверяет $H_0: \mu = \mu_0$ при неизвестной дисперсии. Статистика:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \quad df = n - 1,$$

где s — выборочное стандартное отклонение.

Двухвыборочный t-тест (независимые выборки)

Ниже приведена таблица для Student- и Welch-тестов:

Student		$t = \frac{\bar{x}_1 - \bar{x}_2}{s_p \sqrt{1/n_1 + 1/n_2}}, \quad df = n_1 + n_2 - 2$	$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$
Welch		$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}, \quad df \approx \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{\frac{s_1^4}{n_1^2(n_1+1)} + \frac{s_2^4}{n_2^2(n_2+1)}}$	

Welch-тест предпочтителен, если дисперсии отличаются или объёмы выборок разные.

Парный t-тест

Для каждой пары наблюдений (i) вычисляют разность $(d_i = x_i^{\text{до}} - x_i^{\text{после}})$ и применяют одновыборочный t-тест к массиву разностей. Статистика: $(t = \frac{\bar{d}}{s_d/\sqrt{n}})$ с $(df = n - 1)$.

Многовыборочные аналоги

Для сравнения нескольких средних (>2) применяют однофакторный ANOVA. При наличии нескольких факторов или ковариат используют анализ ковариаций (ANCOVA) или линейную регрессию. Пост-хок сравнения требуют поправок на множественные тесты.

Код: реализация t-тестов на Python

```
import numpy as np
from scipy import stats

# Одновыборочный t-тест
t_stat, p_val = stats.ttest_1samp(x, popmean=mu0)

# Двухвыборочный Welch-тест
t_stat, p_val = stats.ttest_ind(x1, x2, equal_var=False)

# Двухвыборочный Student-тест
```

```
t_stat, p_val = stats.ttest_ind(x1, x2, equal_var=True)
```

```
# ■■■■■■ t-■■■■■
```

```
t_stat, p_val = stats.ttest_rel(before, after)
```

```
# 95% CI ■■■ ■■■■■■■■: t.interval
```

```
alpha = 0.05
```

```
mean = np.mean(x)
```

```
se = stats.sem(x)
```

```
ci = stats.t.interval(confidence=1-alpha, df=len(x)-1, loc=mean, scale=se)
```

Модуль SciPy возвращает t-статистику и p-value. Доверительный интервал для среднего вычисляется через функцию t.interval.

Критерий χ^2 (хи-квадрат)

Критерий χ^2 применяется к категориальным данным. Он сравнивает наблюдаемые частоты с ожидаемыми при верной H_0 . Тестовая статистика:

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

где O — наблюдаемая частота, E — ожидаемая частота. χ^2 имеет χ^2 -распределение с $(r-1)(c-1)$ степенями свободы.

Типы χ^2 -тестов

Тест независимости: проверяет, есть ли связь между двумя категориальными переменными (таблица сопряжённости). Тест однородности: сравнивает распределения категорий в нескольких выборках (те же формулы, что и тест независимости). Тест согласия: проверяет соответствие наблюдаемых частот заданному распределению (p_k) (goodness-of-fit).

Предпосылки

Независимость наблюдений. Работа с частотами (целыми счетчиками). Ожидаемые частоты достаточны (обычно ≥ 5); при малых частотах в 2×2 таблицах используют точный тест Фишера.

Меры силы связи

Для таблиц 2×2 можно вычислить отношение шансов (OR) и его доверительный интервал. Для таблиц $(r \times c)$ используют меру Крамера:

$$V = \sqrt{\frac{\chi^2}{N \cdot \min(r-1, c-1)}}$$

Код: χ^2 -тесты и точный тест Фишера

```
import numpy as np
from scipy import stats

# 2x2: expected = [10000, 10000], observed = [10200, 11000]
table = np.array([[1020, 10000-1020], [1100, 10000-1100]])

#  $\chi^2$ -тест
chi2, p, df, expected = stats.chi2_contingency(table, correction=False)

#  $\chi^2$ -тест с поправкой
a = np.array([52, 48, 60, 40])
expected = a.sum() * np.array([0.25, 0.25, 0.25, 0.25])
chi2_stat, p = stats.chisquare(f_obs=a, f_exp=expected)

# Точный тест Фишера
odds_ratio, p_fisher = stats.fisher_exact(table)
```

Функция `chi2_contingency` возвращает χ^2 -статистику, p-value, степени свободы и ожидаемые частоты. Для малых частот используют `stats.fisher_exact`.

P-value и интерпретация

P-value — это вероятность получить статистику теста не менее экстремальную, чем наблюдаемая, при верной H_0 . Низкое p-value говорит о том, что наблюдение маловероятно под H_0 .

p-value не является вероятностью того, что H_0 истинна. Высокое значение p-value лишь означает недостаток доказательств для отклонения H_0 .

Распространённые заблуждения:

Большое p-value не означает отсутствия эффекта: возможны слабый эффект или малая выборка. Малое p-value не гарантирует практическую значимость: эффект может быть статистически значимым, но слишком малым для бизнеса. p-value зависит от размера выборки: при огромных объёмах даже маленькие эффекты будут значимыми.

Лучше сообщать эффект вместе с доверительным интервалом и p-value.

Ошибки I и II рода и мощность

Ошибки I и II рода относятся к неправильным решениям при проверке гипотез.

Ошибка I рода (Type I): отвергнуть H_0 , когда она верна. Вероятность = α (уровень значимости). Ошибка II рода (Type II): не отвергнуть H_0 , когда H_1 верна. Вероятность = β . Мощность теста = $(1-\beta)$.

Уменьшая α , мы сокращаем риск ложных побед, но увеличиваем вероятность пропустить реальный эффект (растёт β). Для высокой мощности при низком α нужно увеличивать объём выборки.

В А/В-экспериментах обычно выбирают $\alpha=0.05$ и мощность 80–90%.

Расчёт объёма выборки и MDE

Для планирования экспериментов необходимо задать минимально обнаружимый эффект (MDE), уровень значимости (α) и мощность. При равных размерах групп:

Разница долей:

$$n \approx \frac{2 \left(z_{1-\alpha/2} + z_{1-\eta} \right)^2}{p(1-p)} \Delta^2,$$

Разница средних:

$$n \approx \frac{2 \left(z_{1-\alpha/2} + z_{1-\eta} \right)^2}{\sigma^2} \Delta^2,$$

где (σ) — стандартное отклонение метрики, (p) — базовая доля успехов, (Δ) — эффект. Чем меньше (α) и больше мощность, тем больше требуется выборка.

Бутстрап

Бутстрап оценивает распределение статистики путём многократного ресэмплинга исходных данных с возвращением. Он не предполагает нормальности и подходит для тяжёлых хвостов, медиан, квантилей, ratio-метрики.

Одновыборочный бутстрап

Алгоритм: Имеется выборка $(x_1, \dots, x_n)$. Многократно (обычно 5–20 тыс. раз) создают бутстрап-выборки размера n с возвращением. На каждой выборке вычисляют статистику $\hat{\theta}$ (например, среднее, медиану).

Распределение $\hat{\theta}$ используется для построения доверительного интервала (по перцентилям) или для оценки p-value.

Для проверки H_0 данные сдвигают так, чтобы H_0 выполнялась, затем бутстрапируют из этих сдвинутых данных. p-value вычисляют как долю бутстрап-оценок, не менее экстремальных, чем наблюдаемая.

Двухвыборочный бутстрап

Подходы: Интервальный: бутстрапируют выборки A и B независимо, на каждой итерации вычисляют $\Delta = \theta(A) - \theta(B)$ и строят интервал по перцентилям. Если 0 не входит в интервал, H_0 отвергают. Гипотеза под нулевой: данные центрируют (вычитают наблюдаемое среднее, добавляют общее), бутстрапируют и получают p-value как долю $|\Delta| \geq |\Delta_{\text{obs}}|$.

Код: пример бутстрапа

```
import numpy as np

# 95% CI
def bootstrap_ci_mean(x, n_resamples=10000, alpha=0.05, seed=0):
    rng = np.random.default_rng(seed)
    n = len(x)
    stats = np.empty(n_resamples)
    for i in range(n_resamples):
        sample = rng.choice(x, size=n, replace=True)
        stats[i] = sample.mean()
    lower = np.percentile(stats, 100 * (alpha/2))
    upper = np.percentile(stats, 100 * (1 - alpha/2))
    return lower, upper

#
data = np.array([1.2, 1.5, 0.9, 1.1, 1.4])
ci = bootstrap_ci_mean(data)
```

Бутстрап удобен для сложных метрик и не требует предположений о нормальности.

Перестановочный тест

Перестановочный тест (randomization test) проверяет гипотезы путём случайных перестановок меток групп. Под нулевой гипотезой метки обменяемы.

Двухвыборочный перестановочный тест

Алгоритм: Рассчитать наблюдаемую статистику эффекта $(T_{\text{ext}\{obs\}})$. Объединить данные из A и B. Многократно перемешивать данные, деля их снова на группы, и на каждой перестановке вычислять (T^*) . $p\text{-value} = \text{доля перестановок, где } (|T^*| \geq |T_{\text{ext}\{obs\}}|)$ (двусторонний тест).

Одновыборочный (sign-flip) тест

Для одной выборки или парных наблюдений перестановочный тест выполняют, случайно меняя знак у каждого отклонения/разности и рассчитывая статистику. $p\text{-value}$ определяется как доля перестановок, где статистика не менее экстремальна, чем наблюдаемая.

Код: пример перестановочного теста

```
import numpy as np

# =====
def permutation_test(a, b, stat_fn=np.mean, n_permutations=5000, seed=0):
    rng = np.random.default_rng(seed)
    a = np.asarray(a)
    b = np.asarray(b)
    t_obs = stat_fn(b) - stat_fn(a)
    combined = np.concatenate([a, b])
    n_a = len(a)
    count = 0
    for _ in range(n_permutations):
        rng.shuffle(combined)
        a_star = combined[:n_a]
        b_star = combined[n_a:]
        t_perm = stat_fn(b_star) - stat_fn(a_star)
        if abs(t_perm) >= abs(t_obs):
            count += 1
    p_val = (count + 1) / (n_permutations + 1)
    return t_obs, p_val

# =====
a = np.array([10, 12, 9, 11])
b = np.array([13, 14, 10, 12])
statistic, p_value = permutation_test(a, b)
```

Перестановочный тест обеспечивает $p\text{-value}$ без распределительных предпосылок и хорошо работает на небольших выборках.