

Статистика в анализе данных

Z-тест, t-тест, χ^2 -тест, p-value, доверительные интервалы, ошибки I/II рода, бутстрап и перестановочные тесты

Формулы, практические предпосылки и примеры на Python (NumPy + SciPy).

Дата: 19.02.2026

1. Каркас проверки гипотез

Статистический тест — это процедура принятия решения по нулевой гипотезе H_0 на основе данных. Обычно определяют статистику теста T и правило отклонения H_0 при малых p -value.

Базовые понятия:

Термин	Смысл (коротко)	Типичный вопрос в аналитике
H_0 (нулевая гипотеза)	Эффекта/различий нет (или равно фиксированному значению).	«Конверсии А и В равны?»
H_1 (альтернатива)	Эффект есть (двусторонняя/односторонняя).	«В лучше А?»
Статистика теста	Число, измеряющее расхождение данных с H_0 .	z , t , χ^2 и др.
p -value	P (получить результат не менее экстремальный H_0 верна).	«Насколько данные совместимы с H_0 ?»
α (уровень значимости)	Допустимый риск ошибки I рода (ложноположительной).	0.05 или 0.01
Доверительный интервал	Диапазон правдоподобных значений параметра.	«Каков эффект и его неопределенность?»

Нотация (часто используемая):

Пусть θ — параметр (среднее, доля, разница средних и т.д.),
 $\hat{\theta}$ — его оценка по данным, $SE(\hat{\theta})$ — стандартная ошибка.

Общая форма тестовой статистики:

$$\text{statistic} = (\hat{\theta} - \theta_0) / SE(\hat{\theta})$$

2. Z-тест

Z-тест — семейство тестов, в которых статистика теста при верной H_0 имеет (или хорошо аппроксимируется) стандартным нормальным распределением $N(0,1)$.

Когда используют

Чаще всего: (1) тесты долей (конверсий) при больших объемах; (2) тесты средних, когда генеральное стандартное отклонение σ известно (в практике — редко) либо n очень большое.

Требования к данным

Требование	Почему важно	Комментарий
Независимость наблюдений	Иначе SE занижается, p-value становится слишком маленьким.	В A/B обычно работаем на уровне пользователей, не событий.
Достаточно большой n	Нормальная аппроксимация (ЦПТ) для среднего/доли.	Для долей — условия $n \cdot p$ и $n \cdot (1-p)$.
Для теста среднего: σ известно	Классический z-тест для среднего использует σ .	Если σ неизвестно — обычно t-тест.

Формулы

1) Одновыборочный z-тест для среднего (σ известно):

$$H_0: \mu = \mu_0$$

$$z = (\bar{x} - \mu_0) / (\sigma / \sqrt{n})$$

2) Одновыборочный z-тест для доли:

$$H_0: p = p_0$$

$$\hat{p} = x / n$$

$$z = (\hat{p} - p_0) / \sqrt{p_0(1-p_0)/n}$$

3) Двухвыборочный z-тест для разницы долей (A/B конверсия), pooled под H_0 :

$$H_0: p_1 = p_2$$

$$\hat{p}^1 = x_1/n_1, \hat{p}^2 = x_2/n_2$$

$$\hat{p} = (x_1 + x_2) / (n_1 + n_2)$$

$$z = (\hat{p}^1 - \hat{p}^2) / \sqrt{\hat{p}(1-\hat{p})(1/n_1 + 1/n_2)}$$

Много групп

Отдельного «k-выборочного z-теста» обычно не используют. Для средних k групп — ANOVA (F-тест), для категорий/долей k групп — χ^2 -тест. При множественных сравнениях применяют поправки (Holm/Bonferroni/FDR).

Пример на Python (SciPy building blocks)

```
from scipy import stats

p_two_sided = 2 * (1 - stats.norm.cdf(abs(z)))
zcrit = stats.norm.ppf(0.975) # 95% CI
CI = (theta_hat - zcrit * SE, theta_hat + zcrit * SE)
```

3. Квантили, p-value и доверительные интервалы

Квантиль стандартной нормали

Квантиль z_p — число, такое что $P(Z \leq z_p) = p$ для $Z \sim N(0,1)$. Обозначение: $z_p = \Phi^{-1}(p)$.

Уровень	Квантиль	Где используется
90% CI (двусторонний)	$z_{0.95} \approx 1.645$	отсекаем 5% в каждом хвосте суммарно 10%
95% CI (двусторонний)	$z_{0.975} \approx 1.96$	отсекаем 2.5% в каждом хвосте
99% CI (двусторонний)	$z_{0.995} \approx 2.576$	отсекаем 0.5% в каждом хвосте

p-value

Определение:

$p\text{-value} = P(\text{получить результат не менее экстремальный, чем наблюдаемый} \mid H_0 \text{ верна})$

Для z-статистики:

двусторонний: $p = 2 * (1 - \Phi(|z|))$

правосторонний: $p = 1 - \Phi(z)$

левосторонний: $p = \Phi(z)$

Важно:

- p-value НЕ равен вероятности истинности H_0 .
- Малый p-value означает низкую совместимость данных с H_0 .

Доверительный интервал

Общий вид:

$$CI_{1-\alpha} = \theta^{\pm} \pm z_{1-\alpha/2} * SE(\theta^{\pm})$$

Связь с двусторонним тестом:

θ_0 не входит в 95% CI $\Leftrightarrow p\text{-value} < 0.05$

4. t-тест

t-тест — семейство тестов о средних, когда σ неизвестно и оценивается по данным. Статистика под H_0 имеет t-распределение Стьюдента с df степенями свободы.

Варианты t-теста

Вариант	Гипотеза	Когда использовать	Функция SciPy
Одновыборочный	$H_0: \mu = \mu_0$	Сравнить среднее с константой	<code>stats.ttest_1samp</code>
Двухвыборочный (Welch)	$H_0: \mu_1 = \mu_2$	По умолчанию для A/B по средним	<code>stats.ttest_ind(equal_var=False)</code>
Двухвыборочный (Student)	$H_0: \mu_1 = \mu_2$	Если дисперсии равны	<code>stats.ttest_ind(equal_var=True)</code>
Парный	$H_0: E(d)=0$	До/после, matched design	<code>stats.ttest_rel</code>

Формулы

- 1) One-sample:

$$t = (\bar{x} - \mu_0) / (s / \sqrt{n}), \quad df = n - 1$$
- 2) Two-sample Welch:

$$t = (\bar{x}_1 - \bar{x}_2) / \sqrt{s_1^2/n_1 + s_2^2/n_2}$$
- 3) Student (equal variances):

$$sp^2 = [(n_1-1)s_1^2 + (n_2-1)s_2^2] / (n_1+n_2-2)$$

$$t = (\bar{x}_1 - \bar{x}_2) / [sp * \sqrt{1/n_1 + 1/n_2}]$$

$$df = n_1 + n_2 - 2$$

95% CI через `stats.t.interval`

```
from scipy import stats
ci = stats.t.interval(confidence=0.95, df=df, loc=theta_hat, scale=SE)
```

5. χ^2 -тест (хи-квадрат)

χ^2 -тесты применяются к категориальным данным (частотам) и сравнивают наблюдаемые частоты O с ожидаемыми E : $\chi^2 = \sum (O-E)^2 / E$.

Основные версии

Версия	Что проверяет	Данные	Функция SciPy
Независимость	Связь двух категориальных переменных	$r \times c$ таблица	<code>stats.chi2_contingency</code>
Согласие	Соответствие заданному распределению	$1 \times k$ частоты	<code>stats.chisquare</code>
Малые частоты (2x2)	Точный тест	2x2 таблица	<code>stats.fisher_exact</code>

Размер эффекта

Odds Ratio (2x2):

$$OR = (a*d) / (b*c)$$

$$SE(\log OR) = \sqrt{1/a + 1/b + 1/c + 1/d}$$

Cramér's V ($r \times c$):

$$V = \sqrt{\chi^2 / (N * \min(r-1, c-1))}$$

6. p-value и ошибки I/II рода

p-value — вероятность увидеть столь же (или более) экстремальные данные при условии, что H_0 верна. $p \leq \alpha \rightarrow$ отвергаем H_0 на уровне α . $p > \alpha \rightarrow$ недостаточно оснований отвергнуть H_0 .

Матрица решений

Реальность / Решение	Не отвергли H_0	Отвергли H_0
H_0 истинна	Верно	Ошибка I рода (α)
H_1 истинна	Ошибка II рода (β)	Верно

Мощность = $1 - \beta$.

Компромисс: при фиксированном n уменьшение α обычно увеличивает β .

7. Бутстрап

Бутстрап — ресэмплирование с возвращением для оценки распределения статистики. Часто используют для CI, а для p-value — через нулевую модель (shift/centering).

One-sample CI:

resample x^* -> θ^* -> percentiles -> CI

Two-sample CI:

resample A^*, B^* -> Δ^* -> percentiles -> CI

8. Перестановочный тест

Permutation test строит нулевое распределение, переставляя метки групп. Хорош для p-value в A/B при обменности под H_0 .

$$p \approx (\#\{ |T^*| \geq |T_{\text{obs}}| \} + 1) / (M + 1)$$

9. Практический чек-лист

Задача	Рекомендуемый тест	Когда лучше альтернатива
A/B по конверсии	z-test долей или χ^2 (2x2)	малые частоты: Fisher; модельно: логистическая регрессия
A/B по среднему	Welch t-test	тяжелые хвосты: permutation / bootstrap CI
Категориальные распределения	χ^2 (r x c)	слишком малые E: укрупнить категории или точные методы
Сложная метрика	bootstrap / permutation	GLM/регрессия при ковариатах

Отчет: эффект + 95% CI + p-value + заранее выбранный α . Следите за единицей независимости (обычно пользователь).